

SOBRE A MATEMÁTICA ENVOLVIDA NO PROJETO SAÚDE RESPONSIVA

Manual de Modelagem Matemática, Fusão Fisiológica e Inferência de Dados Fantasma

Este manual descreve em detalhes a infraestrutura matemática e biológica implementada na plataforma **Saúde Responsiva**. O sistema foi projetado para ler dados de wearables redundantes, remover ruídos físicos causados por movimentação, fundir leituras de sensores de forma ótima via inferência Bayesiana e estimar variáveis latentes internas (Dados Fantasma) através de Filtros de Kalman não-lineares, correlacionando-as com a ontologia de teses de saúde da USP.

1. Simulação Fisiológica: Processo de Ornstein-Uhlenbeck (OU)

A frequência cardíaca e os estados internos do corpo não se comportam como random walks independentes. Eles possuem mecanismos homeostáticos de autorregulação (feedback autônomo). Modelar-se essa dinâmica usando a Equação Diferencial Estocástica (SDE) de Ornstein-Uhlenbeck:

$$dX_t = \theta * (\mu - X_t) dt + \sigma * dW_t$$

Onde: θ é a taxa de reversão que determina a velocidade de retorno ao equilíbrio; μ é o setpoint de equilíbrio fisiológico; σ é a volatilidade intrínseca do organismo; e dW_t é o incremento do processo de Wiener (ruído Browniano).

Aplicação no código: Implementado na geração de frequência cardíaca artificial em `physiological_signal_model.py` e no modelo de transição biológica do Filtro de Kalman em `state_space_model.py`.

2. Reconciliação Bayesiana de Sensores (BLUE & EWMA)

wearables redundantes possuem diferentes níveis de precisão. O estimador BLUE (Best Linear Unbiased Estimator) fornece a combinação linear com variância mínima imparcial:

$$x_{fused} = \sum (w_i * z_i) \text{ onde } w_i = (1/\sigma^2_i) / \sum (1/\sigma^2_j)$$

A variância de cada sensor é estimada online pelo desvio quadrático móvel exponencial (EWMA):

$$\sigma^2_{new} = \lambda * \sigma^2_{old} + (1 - \lambda) * (z_t - x_{fused})^2$$

Onde $\lambda \in (0,1)$ dita o peso do histórico. *Aplicação no código:* A classe `AdaptiveSensorFusion` (em `sensor_fusion.py`) ajusta os pesos em tempo real de forma que sensores ruidosos perdem peso instantaneamente.

3. Separação Física de Ruídos (DWT Wavelet)

Para remover artefatos de movimento sem defasar o sinal ou suavizar picos reais (como faz a média móvel), utilizamos a Decomposição Wavelet Discreta (DWT). O sinal é decomposto e limiarizado suavemente pelo limiar universal:

$$\lambda = \sigma * \text{sqrt}(2 * \ln(N))$$

O ruído σ é estimado robustamente no domínio de frequências pela mediana absoluta dos coeficientes (MAD):

$$\sigma = \text{median}(|d_1|) / 0.6745$$

Aplicação no código: A classe WaveletDenoiser (em noise_separation.py) decompõe o sinal em wavelets Daubechies 'db4' para realizar denoising adaptativo.

4. Estimativa de Sinais Ocultos: Dados Fantasma via EKF e UKF

Os wearables de pulso medem apenas a superfície (frequência cardíaca e temperatura), mas a verdadeira condição hemodinâmica do paciente depende de estados latentes não-observáveis direta ou continuamente (Dados Fantasma: Pressão Sistólica/Diastólica, SpO₂ e Glicose). Modelamos a fisiologia como um sistema de espaço de estados estimável pelo Filtro de Kalman Estendido (EKF):

Predição:

$$x_{\text{pred}} = f(x_{k-1}) \mid P_{\text{pred}} = F * P_{k-1} * F^T + Q$$

Atualização:

$$K = P_{\text{pred}} * H^T * (H * P_{\text{pred}} * H^T + R)^{-1}$$

$$x_k = x_{\text{pred}} + K * (z - h(x_{\text{pred}})) \mid P_k = (I - K * H) * P_{\text{pred}}$$

Onde **F** e **H** são as matrizes Jacobianas analíticas lineares de transição e observação fisiológica. O envelope de variância diagonal de **P_k** fornece o intervalo de confiança dinâmico da estimativa fantasma.

Aplicação no código: Mapeado nas classes ExtendedKalmanFilter e UnscentedKalmanFilter em state_space_model.py.

5. Anomalias Fisiológicas (Distância de Mahalanobis)

Diferente da distância Euclidiana clássica, a distância de Mahalanobis leva em consideração a covariância e correlação mútua das features de saúde:

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}$$

A distância quadrática D_M^2 obedece a uma distribuição de Qui-Quadrado (χ^2). Medimos a probabilidade (p-value) de a leitura atual ocorrer sob condições basais normais. Se o p-value < 0.01, classificamos como anômalo.

6. Rede Diagnóstica Bayesiana & Ontologia USP

A inferência clínica é efetuada no espaço de probabilidade posterior das patologias (C_i) usando as variáveis fantasmas estimadas $\mathbf{x}$ e métricas de HRV:

$$P(C_i | \mathbf{x}) = P(\mathbf{x} | C_i) * P(C_i) / \sum_j [P(\mathbf{x} | C_j) * P(C_j)]$$

A verossimilhança gaussiana de risco é modulada a partir da distância das estimativas aos limites normais da ontologia de teses da USP (como a faixa saudável de pressão arterial sistólica 90–140 mmHg):

$$P(\mathbf{x}_k | C_i) \propto \exp(- \text{dist}(\mathbf{x}_k, [L_L, L_U])^2 / (2 * \sigma_{tol}^2))$$

Aplicação no código: A classe `BayesianDiagnosticNetwork` calcula e atualiza as probabilidades sob demanda, vinculando o diagnóstico a códigos de faturamento de saúde (ICD-10, SNOMED, MeSH).